



Fecha de entrega: Noviembre 19, 2021



Tecnológico Nacional de México Instituto Tecnológico de Tijuana

SUBDIRECCIÓN ACADÉMICA Departamento de Sistemas y Computación

SEMESTRE agosto - diciembre 2021

CARRERA Ing. Tecnologías de la Información y Comunicación

> MATERIA Y CLAVE: Datos Masivos BDD-1704TI9A

NOMBRE Y MATRÍCULA DEL ALUMNO: Velázquez Farrera César Alejandro 17212937

> NOMBRE DEL TRABAJO: Práctica Evaluativa - Unidad 2

> > UNIDAD POR EVALUAR Unidad II

NOMBRE DEL MAESTRO (A): M.C. José Christian Romero Hernández







Introducción

En esta práctica evaluatoria, intentaremos crear un modelo de aprendizaje de máquina que pueda predecir el tipo de especie de una flor en base a sus características.

- Cargar en un dataframe Iris.csv que se encuentra en https://github.com/jcromerohdz/iris, elaborar la limpieza de datos necesaria para ser procesado por el siguiente algoritmo (Importante, esta limpieza debe ser por medio de un script de Scala en Spark)
 - a. Utilice la librería Mllib de Spark el algoritmo de Machine Learning **multilayer perceptron**

```
import org.apache.spark.ml.classification.MultilayerPerceptronClassifier
import org.apache.spark.ml.evaluation.MulticlassClassificationEvaluator
import org.apache.spark.ml.feature.StringIndexer
import org.apache.spark.ml.feature.VectorAssembler
import org.apache.spark.ml.feature.VectorIndexer
import org.apache.spark.ml.feature.IndexToString
import org.apache.spark.sql.SparkSession
import org.apache.spark.ml.Pipeline

val session = SparkSession.builder().getOrCreate

val iris_data = session.read.option("header","true").option("inferSchema",
true).csv("iris.csv")
```

```
scala> val session = SparkSession.builder().getOrCreate
session: org.apache.spark.sql.SparkSession = org.apache.spark.sql.SparkSession@19a799cb

scala> val iris_data = session.read.option("header","true").option("inferSchema", true).csv("iris.csv")
iris_data: org.apache.spark.sql.DataFrame = [sepal_length: double, sepal_width: double ... 3 more fields]
```

2. ¿Cuáles son los nombres de las columnas?

```
iris_data.columns
```

sepal_length, sepal_width, petal_length, petal_width, species

```
scala> iris_data.columns
res0: Array[String] = Array(sepal_length, sepal_width, petal_length, petal_width, species)
```

3. ¿Cómo es el esquema?

//getting to know the dataset







iris_data.printSchema()

```
scala> iris_data.printSchema()
root
    |-- sepal_length: double (nullable = true)
    |-- sepal_width: double (nullable = true)
    |-- petal_length: double (nullable = true)
    |-- petal_width: double (nullable = true)
    |-- species: string (nullable = true)
```

4. Imprime las primeras 5 columnas.

```
//Printing the first five rows of data
iris_data.head(5)

scala> iris_data.head(5)
res2: Array[org.apache.spark.sql.Row] = Array([5.1,3.5,1.4,0.2,setosa], [4.9,3.0,1.4,0.2,setosa], [4.7,3.2,1.3,0.2,setosa], [4.6,3.1,1.5,0.2,setosa], [5.0,3.6,1.4,0.2,setosa])
```

5. Usa el método describe() para aprender más sobre los datos del DataFrame.

```
//getting to know the dataset
iris_data.printSchema()
```

```
scala> iris data.describe().show()
|summary|
               sepal_length|
                                     sepal_width|
                                                        petal_length|
                                                                             petal_width|
                                                                  150 l
   count
                         150
                                              150 l
                                                                                      150
                                                                                                150
          5.8433333333335 3.0540000000000007 3.758666666666693 1.1986666666666672
                                                                                               null
   meanl
  stddev|0.8280661279778637|0.43359431136217375|
                                                  1.764420419952262 0.7631607417008414
                                                                                               null
                         4.3
                                              2.0
                                                                  1.0
                                                                                     0.1
    min
                                                                                             setosa
                         7.9
                                              4.4
                                                                  6.9
                                                                                      2.5|virginica|
     max
```

6. Haga la transformación pertinente para los datos categóricos los cuales serán nuestras etiquetas a clasificar.

```
//Setting the input columns to a single one as pFeatures
val assembler = new VectorAssembler().setInputCols(Array("sepal_length",
    "sepal_width", "petal_length", "petal_width")).setOutputCol("pFeatures")
val pFeatures = assembler.transform(iris_data)
pFeatures.show(5)

//Indexing the labels (species)
val SpeciesIndexer = new
StringIndexer().setInputCol("species").setOutputCol("indexedSpecies").fit(pFeatures)
println(s"Found labels: ${SpeciesIndexer.labels.mkString("[", ", ", "]")}")
```







```
//Indexing the features
val featuresIndexer = new
VectorIndexer().setInputCol("pFeatures").setOutputCol("indexedFeatures").set
MaxCategories(4).fit(pFeatures)

//Split the dataset into two parts, one for training set and another for
testing.
val splits = pFeatures.randomSplit(Array(0.7, 0.3))
val train = splits(0)
val test = splits(1)
```

```
val layers = Array[Int](4,5,4,3)
```

scala> val featuresIndexer = new VectorIndexer().setInputCol("pFeatures").setOutputCol("indexedFeatures").setMaxCategories(4).fit(pFeatures) featuresIndexer: org.apache.spark.ml.feature.VectorIndexerModel = vecIdx_822095f20e7f

```
scalas val splits = pfeatures, randomsplit(Array(0,7, 0,3))

splits: Array(org.apache.spark.sql.Dataset[org.apache.spark.sql.Row]] = Array([sepal_length: double, sepal_width: double ... 4 more fields])
scalas val train = splits(0)
train: org.apache.spark.sql.Dataset[org.apache.spark.sql.Row] = [sepal_length: double, sepal_width: double ... 4 more fields]
scalas val test = splits(1)
scalas val test = splits(1)
train: org.apache.spark.sql.Dataset[org.apache.spark.sql.Row] = [sepal_length: double, sepal_width: double ... 4 more fields]
scalas val test = splits(1)
test: org.apache.spark.sql.Dataset[org.apache.spark.sql.Row] = [sepal_length: double, sepal_width: double ... 4 more fields]
```

7. Construya el modelo de clasificación y explique su arquitectura.

```
//Training the trainer
val trainer = new
MultilayerPerceptronClassifier().setLayers(layers).setLabelCol("indexedSpeci
es").setFeaturesCol("indexedFeatures").setBlockSize(128).setSeed(System.curr
entTimeMillis).setMaxIter(200)

val labelConverter = new
IndexToString().setInputCol("prediction").setOutputCol("predictedLabel").set
Labels(SpeciesIndexer.labels)

val pipeline = new Pipeline().setStages(Array(SpeciesIndexer,
```







```
featuresIndexer, trainer, labelConverter))
```

```
val model = pipeline.fit(train)
```

```
scala> val layers = #rray[Int][4,5,4,3]
scala> val trainer = new MultilayerPerceptronClassifier().setLayers(layers).setLabelCol('indexedSpecies').setFeaturesCol('indexedFeatures').setBlockSize(128).setSeed(System.currentTimeMillis).setMaxIter(200)
trainer: org.apache.spark.ml.classification.MultilayerPerceptronClassifier = mlpc_fba33818c008
scala> scala> val labelConverter = new IndexToString().setInputCol('prediction').setOutputCol('predictedLabel').setLabels(SpeciesIndexer.labels)
labelConverter: org.apache.spark.ml.feature.indexToString = idxToStr_01de4f1d0e4a
scala> val pipeline = new Pipeline().setStages(Array(SpeciesIndexer, featuresIndexer, trainer, labelConverter))
pipeline: org.apache.spark.ml.Pipeline = pipeline_523a4883f1a0
```

8. Imprima los resultados del modelo.

```
val predictions = model.transform(test)
predictions.show(10)

val evaluator = new
MulticlassClassificationEvaluator().setLabelCol("indexedSpecies").setPredict
ionCol("prediction").setMetricName("accuracy")

val accuracy = evaluator.evaluate(predictions)
println(accuracy)
```

```
scala> val accuracy = evaluator.evaluate(predictions)
accuracy: Double = 0.9347826086956522
scala> println(accuracy)
0.9347826086956522
```

Conclusión

El clasificador Multilayer Perceptron es un modelo sencillo de utilizar, ya que solo se necesita especificar las clases del objeto (características) y las especies, partir los datos y entrenar un modelo.

En base al modelo, podemos notar que el mismo predice el 93.47% de los datos correctamente. Lo que hace que este modelo sea confiable al momento de querer realizar otras predicciones.